

Санкт-Петербургский государственный университет
Факультет прикладной математики – процессов управления
ООП СВ.5005.2022 Прикладная математика, фундаментальная информатика и программирование

Шаго Павел Евгеньевич

*Математическое моделирование и реализация планировщика
процессов для гетерогенных процессорных архитектур*

Выпускная квалификационная работа

Научный руководитель:
кандидат физ.-мат. наук, доцент
Корхов В. В.

Рецензент:
эксперт по архитектуре и сетевому стеку,
ООО НИЦ АЭРОДИСК, Анохин Ю. В.

Санкт-Петербург
2026

Цель работы

разработка и экспериментальная оценка планировщика, обеспечивающего более высокую эффективность вычислений на гетерогенном оборудовании по сравнению со штатным планировщиком ядра Linux

Предмет исследования

методы планирования, учитывающие различие вычислительной мощности ядер

Гетерогенные процессоры в современных устройствах

Сегмент	Примеры	Массово	Сегодня
Смартфоны	Apple A, Snapdragon, Dimensity, Exynos, Tensor	2013	все актуальные
Ноутбуки	Apple M, Intel Core Ultra, Ryzen AI, Snapdragon X	2020	все актуальные
Настольные ПК	Intel Core 12+, Intel Core Ultra	2021	частично
Серверы	NVIDIA GB10	—	экспериментально

Тренд: гетерогенные P/E-архитектуры, возникшие в мобильных SoC, стали нормой для процессоров ПК и ноутбуков. Серверные CPU пока остаются однородными

- 1 Проанализировать и определить наиболее перспективный подход к реализации планировщика
- 2 Построить математическую модель, учитывающую различную вычислительную мощность ядер процессора
- 3 Реализовать разработанный алгоритм и собрать воспроизводимый набор бенчмарков
- 4 Провести эксперимент на гетерогенном оборудовании и оценить результаты в сравнении с базовым планировщиком Linux EEVDF

Сравнение подходов к реализации планировщика

Критерий	В ядре	Модуль	gh0St	sched_ext
Без пересборки ядра	—	+	±	+
Устойчивость к ошибкам реализации	—	—	+	+
Низкие накладные расходы	+	+	—	±
Поддерживаемый интерфейс замены	—	—	±	+
Переносимость между версиями ядра	—	—	±	+

Вывод: sched_ext является лучшим вариантом по приведённым критериям. Умеренные накладные расходы фреймворка — сознательный компромисс за остальные преимущества




Рис. 1. Механизм работы sched_ext

DSQ (dispatch queue)

- SCX_DSQ_LOCAL
- SCX_DSQ_GLOBAL
- пользовательские DSQ

Цикл планирования

- select_cpu()
- enqueue()
- dispatch()
- running / stopping

Загрузка планировщика

- компиляция
- вызов bpf()
- верификатор ядра

Аппаратная платформа

- Ядра: $\mathcal{P} = \{P_1, \dots, P_{K_P}\}$,
 $\mathcal{E} = \{E_1, \dots, E_{K_E}\}$
- Дискретное время $t = 1, 2, 3, \dots$
- Замедление на E-ядре: $\sigma = \eta_P / \eta_E > 1$
- Общий ISA (любая задача может быть выполнена на любом ядре)

Задачи как агенты

- Тип $\theta_i = (v_i, l_i)$: ценность v_i , длина l_i
- Полезность как маргинальный вклад в социальное благосостояние W :
 $U_i = W(s^t) - W_{-i}(s^t) \geq 0$
- Бюджет $B_i(\chi_i) > 0$ по классу обслуживания χ_i :

реального времени
интерактивный
пакетный
фоновый

Временные кванты P/E-ядер процессора – **недолговечный ресурс** (неиспользованный квант теряется безвозвратно). Их распределение моделируется динамическим аукционом VCG с задачами-агентами, максимизирующим социальное благосостояние

Состояние $s^t = (\mathbf{x}^t, \mathbf{b}^t, \Theta^t, \mathcal{N}^t)$

- $\mathbf{x}^t$ – остаточные длительности контрактов
- $\mathbf{b}^t$ – остаточные бюджеты
- Θ^t – типы задач, $\mathcal{N}^t$ – активные задачи

Действие $a_i^t = (a_{i,P}, a_{i,E}) \in \{0, 1\}^2$,
 $a_{i,P} + a_{i,E} \leq 1$

$$\sum_i a_{i,P} \leq K_P^t, \quad \sum_i a_{i,E} \leq K_E^t$$

(K_κ^t – число свободных ядер кластера κ в момент t)

Эффективная ценность ($\kappa \in \{P, E\}$)

$$\phi_\kappa(\theta_i) = v_i - c_\kappa m_\kappa(l_i)$$

$$m_P(l) = l, \quad m_E(l) = \lceil l\sigma \rceil$$

Социальное благосостояние (Беллман, $\delta \in (0, 1)$):

$$W(s^t) = \max_{a^t} \left[\sum_i \phi_i^a + \delta \mathbb{E}[W(s^{t+1})] \right]$$

$$\phi_i^a = a_{i,P} \phi_P(\theta_i) + a_{i,E} \phi_E(\theta_i)$$

Платёж VCG

$$p_i^t = W_{-i}(s^t) - (W(s^t) - \phi_\kappa(\theta_i))$$

Решение аукциона

Задача направляется в DSQ_P или DSQ_E по $\kappa^* = \arg \max_{\kappa \in \{P, E\}} \phi_{\kappa}(\theta_i)$

DSQ_P

$$\phi_P \geq \phi_E$$

P-ядро выгоднее по
эффективной ценности

DSQ_E

$\phi_E > \phi_P$ либо
короткая задача при
перегрузке P-кластера

$$Q_P \geq K_P \text{ и} \\ Q_P K_E > Q_E K_P$$

DSQ_Starved

$$B_i^t < B_i^{\max}/10$$

Низкий приоритет,
обслуживается
после пополнения

Ослабления модели в реализации

- v_i сообщается через вес задачи $p \rightarrow \text{scx.weight}$
- $W_{-i}(s^t) \rightarrow$ кластерная EWMA $\bar{W}_{\kappa}$ по реализованным $|\phi|$
- $l_i \rightarrow$ EWMA по истории исполнения
- Контракт – горизонт планирования, не атомарная единица
- Бюджет – корзина токенов с пополнением во сне ($B_i^{\max} = w_i \cdot \text{BUDGET_MUL}$, $\Delta B_i \propto w_i$)

Система

Ядро Linux 7.0,
Arch Linux
CPU: Intel Core
Ultra 7 265K
8P + 12E, без HT

Сравнение

Linux EEVDF
(эталон)
scx_EEVDF
scx_LAVD
scx_A1349 (VCG)

Бенчмарки

- **hackbench** – массовое порождение процессов с интенсивным межпроцессным обменом и постоянными переключениями контекста
- **sysbench** – oltp_read_only, транзакции чтения к PostgreSQL. Потoki блокируются на ожидании ответа базы данных
- **schbench** – имитация веб-обработчика, рабочие потоки чередуют короткие фазы ожидания и матричных вычислений

Метрики

hackbench: время (с)
sysbench: TPS
schbench: RPS,
p99 / p99.9 (мкс)
RAPL package:
энергия (Дж)

Прогоны

3 уровня нагрузки
 $N = 6$, 95% ДИ

Hackbench: время (с) (меньше — лучше)




Рис. 2. Результаты hackbench

Sysbench OLTP, транзакций в секунду (больше — лучше)




Рис. 3. Результаты sysbench oltp_read_only

schbench: средний RPS (больше — лучше)




Рис. 4. Результаты schbench




Рис. 5. Энергопотребление процессора за всё время тестирования по счётчикам Intel RAPL

- scx_A1349 превосходит штатный EEVDF на hackbench на 4,5 / 8,5 / 1,4% и лидирует на schbench по средней пропускной способности при умеренной и стресс-нагрузке на 51,3 / 55,7%. Задержка p99.9 при стресс-нагрузке 24,5мс против $\approx 1,7$ с у EEVDF
- sysbench единственная нагрузка где scx_A1349 проигрывает EEVDF (1,6 / 0,8 / 7,4%). Отстают все sched_ext-планировщики до 39,7%, причиной могут являться накладные расходы фреймворка
- Разделение вклада отдельных факторов реализации (аукционный платёж, корзина токенов, выбор P-ядра, привязанные к ядрам очереди) выходит за рамки работы и требует серии экспериментов с поочерёдным отключением

- Обоснован выбор `sched_ext` среди четырёх рассмотренных подходов к реализации планировщика
- Построена математическая модель распределения квантов P/E ядер как динамического аукциона VCG
- Реализован планировщик `scx_A1349` на основе построенной модели
- Проведён эксперимент на реальном гетерогенном оборудовании, проведено сравнение со штатным планировщиком Linux и современными eBPF-планировщиками
- По части материалов работы подготовлена статья, прошедшая рецензирование, и сделан доклад на конференции CPS

Спасибо за внимание!

- EEVDF** Earliest Eligible Virtual Deadline First — штатный планировщик ядра Linux с 6.6
- sched_ext** инфраструктура ядра для подключаемых планировщиков на eBPF
 - eBPF** extended Berkeley Packet Filter, верифицируемый байт-код, исполняемый в ядре
- ghOSt** пользовательский планировщик от Google, политика в user-space
- scx_LAVD** Latency-Aware Virtual Deadline, eBPF-планировщик с учётом отзывчивости
- scx_EEVDF** порт EEVDF поверх sched_ext, эталон накладных расходов фреймворка
 - DSQ** Dispatch Queue, очередь готовых задач внутри sched_ext
 - VCG** Vickrey-Clarke-Groves, аукцион с правдивыми оценками
 - MDP** Markov Decision Process, марковский процесс принятия решений
 - EWMA** Exponentially Weighted Moving Average, экспоненциально-взвешенное скользящее среднее
 - RAPL** Running Average Power Limit, счётчики энергии Intel
- p99 / p99.9** 99-й и 99,9-й процентиля задержки
- P / E ядра** Performance / Efficient ядра в гибридной архитектуре Intel
 - σ** коэффициент замедления, отношение пиковой производительности P-ядра к E-ядру

Пример: $K_P = K_E = 1$, одно свободное ядро типа κ

Победитель:

$$i^* = \arg \max_{i \in \mathcal{N}^t, B_i^t > 0} \phi_\kappa(\theta_i) + \delta^{m_\kappa(l_i)} \bar{W}_\kappa$$

где $m_P(l) = l$, $m_E(l) = \lceil l \cdot \sigma \rceil$

Платёж победителя:

$$p_{i^*} = \phi_\kappa(\theta_j) + (\delta^{m_\kappa(l_j)} - \delta^{m_\kappa(l_{i^*})}) \bar{W}_\kappa$$

где j — задача на втором месте, $\bar{W}_\kappa$ — ожидаемое будущее благосостояние кластера.

$\phi_P(\theta_i) > \phi_E(\theta_i)$ выполняется не всегда. При малом v_i и большом l_i E-ядро может дать большую эффективную ценность ($c_E \lceil l_i \sigma \rceil < c_P l_i$ при $\sigma < c_P / c_E$). Оптимальная стратегия нетривиальна.

- [1] Lions J. A Commentary on the Sixth Edition UNIX Operating System. — Sydney: The University of New South Wales, 1977.
- [2] Kravetz M., Franke H., Nagar S., Ravindran R. Enhancing Linux Scheduler Scalability // Proceedings of the Ottawa Linux Symposium. — 2001.
- [3] Love R. Linux Kernel Development. — 2nd ed. — Indianapolis: Novell Press, 2005. — 401 p.
- [4] Wong C. S., Tan I. K. T., Kumari R. D., Lam J. W., Fun W. Fairness and Interactive Performance of O(1) and CFS Linux Kernel Schedulers // International Symposium on Information Technology (ITSim 2008). — Kuala Lumpur: IEEE, 2008. — P. 1–6.
- [5] Stoica I., Abdel-Wahab H. Earliest Eligible Virtual Deadline First: A Flexible and Accurate Mechanism for Proportional Share Resource Allocation: Technical Report TR-95-22. — Norfolk: Old Dominion University, 1995.
- [6] Greenhalgh P. Big.LITTLE Processing with ARM Cortex-A15 & Cortex-A7: ARM White Paper. — Cambridge: ARM Ltd., 2011.
- [7] Rotem E. et al. Alder Lake Architecture // 2021 IEEE Hot Chips 33 Symposium (HCS). — Palo Alto, CA, USA, 2021. — P. 1–23. — DOI: 10.1109/HCS52781.2021.9567097.
- [8] Conti F., Paulin G., Garofalo A., Rossi D., Di Mauro A., Rutishauser G., Ottavi G., Eggimann M., Okuhara H., Benini L. Marsellus: A Heterogeneous RISC-V AI-IoT End-Node SoC with 2-to-8b DNN Acceleration and 30%-Boost Adaptive Body Biasing // IEEE Journal of Solid-State Circuits. — 2024. — Vol. 59, No. 1. — P. 128–142.
- [9] Energy Aware Scheduling [Электронный ресурс] // Linux Kernel Documentation. — URL: <https://www.kernel.org/doc/html/latest/scheduler/sched-energy.html> (дата обращения: 14.11.2025).
- [10] Corbet J. The BPF extensible scheduler class [Электронный ресурс] // LWN.net. — 30.11.2022. — URL: <https://lwn.net/Articles/916291/> (дата обращения: 20.11.2025).
- [11] Corbet J. Sched_ext at LPC 2024 [Электронный ресурс] // LWN.net. — 2024. — URL: <https://lwn.net/Articles/991205/> (дата обращения: 11.09.2025).

- [12] Humphries J. T., Natu N., Chaugule A., Weisse O., Rhoden B., Don J., Rizzo L., Rombakh O., Turner P., Kozyrakis C. gh0St: Fast & Flexible User-Space Delegation of Linux Scheduling // Proceedings of the 28th ACM Symposium on Operating Systems Principles (SOSP 2021). — New York: ACM, 2021. — P. 588–604.
- [13] Tang Q., Gao X., Li G., Lin J. Optimizing Linux Scheduling Based on Global Runqueue with SCX // IEEE International Conference on Systems, Man, and Cybernetics (SMC 2024). — IEEE, 2024.
- [14] Xu J., Wolff D., Han X. Y., Li J., Roychoudhury A. Concurrency Testing in the Linux Kernel via eBPF: preprint. — arXiv, 2025. — arXiv:2504.21394.
- [15] Mao J., Ujcich B. E., Ma S. Rethinking Provenance Completeness with a Learning-Based Linux Scheduler: preprint. — arXiv, 2025. — arXiv:2510.08479.
- [16] Wang X., Jia S., Huang Z., Cao J., Song M. Mixture-of-Schedulers: An Adaptive Scheduling Agent as a Learned Router for Expert Policies: preprint. — arXiv, 2025. — arXiv:2511.11628.
- [17] Galin M., Hedblom A. Linux Kernel Scheduler Evaluation for Performance-Critical Telecom Workloads: Master's Thesis. — Linköping: Linköping University, 2025. — 74 p.
- [18] Van Craeynest K., Jaleel A., Eeckhout L., Narvaez P., Emer J. S. Scheduling Heterogeneous Multi-Cores through Performance Impact Estimation (PIE) // Proceedings of the 39th Annual International Symposium on Computer Architecture (ISCA 2012). — New York: ACM, 2012. — P. 213–224.
- [19] Sano R. A Dynamic Mechanism Design for Scheduling with Different Use Lengths: KIER Discussion Paper No. 924. — Kyoto: Institute of Economic Research, Kyoto University, 2015.
- [20] Dobzinski S., Lavi R., Nisan N. Multi-unit Auctions with Budget Limits // Games and Economic Behavior. — 2012. — Vol. 74, No. 2. — P. 486–503.